

Numer indeksu: 119093

Grupa: 3

Temat: Analiza i grupowanie danych przy użyciu algorytmu K-Means oraz wizualizacja t-SNE.

Imię i nazwisko: Jan Chrzanowski

Analiza

Zbiór danych iris zawiera 150 wierszy zawierających dane kwiatków (szerokość i długość kielicha i płatków) każdy z nich przyporządkowany do jednego z trzech gatunków (Setosa, Versicolor, Virginica)

Zbiór jest idealnie zbalansowany po 50 próbek na klasę. Analiza wykazała, że cechy płatków pozwalają na znacznie lepszą separację gatunków niż cechy działki kielicha.

Przeprowadzona analiza K-Mean nie zna etykiet czyli nazw kwiatków.

Przyporządkowuje ona dane do innych najbardziej podobnych elementów tworząc skupiska oznaczające dane gatunki.

Metryki

Na podstawie porównania wyników grupowania z rzeczywistymi etykietami, wyznaczono następujące metryki:

Accuracy (Dokładność): 0.89

	precision	recall	f1-score	support
setosa	1.00	1.00	1.00	50
versicolor	0.77	0.96	0.86	50
virginica	0.95	0.72	0.82	50
accuracy			0.89	150
macro avg	0.91	0.89	0.89	150
weighted avg	0.91	0.89	0.89	150


Wysoki wynik F1-Score dla klasy Setosa potwierdza jej całkowitą separowalność. Nieco niższe wyniki dla pozostałych klas wynikają z fizycznego podobieństwa cech gatunków Versicolor i Virginica.

Wynik precyzji oznacza nieomylnność algorytmu. Możemy zauważyć że dla setosy jest on w stu procentach wiarygodny a w przypadku versicolor możemy spodziewać się niedokładnego dopasowania

Niski recall w virgini oznacza że sporo z nich zostało zakwalifikowanych jako versicolor (bo setosa ma wynik 1.00 czyli ma wszystko prawidłowe). Support informuje nas o liczności wystąpień po analizie. Możemy zauważyć że jest on zbalansowany

Wizualizację przy wykorzystaniu algorytmu T-SNE w postaci wykresu 2D po klasyfikacji/grupowaniu

Zastosowano algorytm t-SNE ($n_components=2$, $perplexity=30$) w celu zredukowania danych z przestrzeni 4D do 2D.



Wizualizacja t-SNE potwierdza strukturę skupisk. Wykres wyraźnie pokazuje trzy grupy punktów. Fakt, że kolory nadane przez K-Means pokrywają się z fizycznymi skupiskami na mapie t-SNE, dowodzi, że algorytm grupowania poprawnie rozpoznał strukturę danych Iris bez znajomości etykiet.